Institut supérieur d'informatique
et de mathématiques de Monastir

Année Universitaire : 2022/2023



Niveau : L3 INFO
Enseignante : Asma KERKENI

Big Data

– TP1 : Initiation à Hadoop –

Partie 1 : Préparation de la machine virtuelle

1. Création de la machine virtuelle

- Installez VirtualBox (https://www.virtualbox.org/)
- Cloudera fournit une machine virtuelle où Hadoop ainsi qu'un grand nombre d'outils de son écosystème, sont préinstallés. Télécharger la machine virtuelle disponible ici : http://content.udacity-data.com/courses/ud617/Cloudera-Udacity-Training-VM-4.1.1.c.zip
  Utilisez l'utilitaire 7-zip pour décompresser le fichier. C'est une machine Linux, distribution CentOS.
- Démarrez VirtualBox. Cliquez sur le bouton « **Nouveau** » pour créer une nouvelle machine virtuelle.
- Donnez-lui le nom « **Hadoop** », sélectionnez « **Linux** » puis « **Ubuntu (64 bits)** » puis continuez.
- Pour la taille de la mémoire, donnez au moins **1024 Mo** (vous puissiez donner plus) puis continuez.
- Sélectionnez « **Utiliser un fichier de disque dur virtuel existant** », naviguez jusqu'à l'emplacement où vous avez décompresser le fichier de la machine virtuelle Cloudera et dans ce répertoire, sélectionnez le fichier « **ClouderaTraining-VM-4.1.1.c.vmdk** ». Cela devrait terminer l'installation et vous devriez voir une nouvelle machine virtuelle dans VirtualBox.

2. Configurer la communication réseau pour la VM

- Sélectionnez la nouvelle machine virtuelle créée dans VirtualBox, à gérer.
- Sélectionnez le bouton « **Configuration** » puis l'onglet « **Réseau** ».
- Sous « **Interface 1** », choisir le mode d'accès réseau « **Accès par pont** » puis cliquer sur **OK.**
- Vous devriez maintenant pouvoir sélectionner votre image de machine virtuelle et cliquer sur le bouton « **Démarrer** » pour lancer la VM.

- Au démarrage de la machine, Hadoop est fonctionnel. Il n'y a pas de manipulations particulières à faire de ce côté-là.



Partie 2 : Manipulation de HDFS

- Démarrez votre machine virtuelle.
- La machine virtuelle est en anglais par défaut, ce qui est gênant pour le clavier... Pour le changer, allez dans la barre de menu de la distribution Linux : **System –> Preferences –> Keyboard –> Layouts.**
- Lancez un terminal.
- Sous le répertoire **/udacity_training/data**, vous trouverez deux sous-répertoires : code et data dans lesquels on trouvera et on sauvegardera respectivement les codes des mappers et reducers, et les données sources et résultats.
- Déplacez-vous sous le répertoire **/udacity_training/data**, et vérifiez que le fichier **purchases.txt** existe bien.

Toutes les commandes interagissant avec le système de fichiers Hadoop commencent par `hadoop fs`. Ensuite, les options rajoutées sont très largement inspirées des commandes Unix standard.

Créez un répertoire dans HDFS, appelé « myinput ». Pour cela, tapez :

```
hadoop fs -mkdir myinput
```

Pour copier le fichier purchases.txt dans HDFS sous le répertoire myinput, il s'agit e se placer dans le répertoire local data où se trouve le fichier, puis tapez la commande :

```
hadoop fs -put purchases.txt myinput/
```

Pour afficher le contenu du répertoire « myinput », la commande est :

```
hadoop fs -ls myinput
```

Pour **visualiser les dernières lignes du fichier**, tapez :

```
hadoop fs -tail myinput/purchase.txt
```

On obtient:

```
[training@localhost udacity_training]$ hadoop fs -ls myinput
Found 1 items
-rw-r--r-- 1 training supergroup 211312924 2021-10-05 18:01 myinput/purchase.txt
[training@localhost udacity_training]$ hadoop fs -tail myinput/purchase.txt
31 17:59 Norfolk Toys 164.34 MasterCard
2012-12-31 17:59 Chula Vista Music 380.67 Visa
2012-12-31 17:59 Hialeah Toys 115.21 MasterCard
2012-12-31 17:59 Indianapolis Men's Clothing 158.28 MasterCard
2012-12-31 17:59 Norfolk Garden 414.09 MasterCard
2012-12-31 17:59 Baltimore DVDs 467.3 Visa
2012-12-31 17:59 Santa Ana Video Games 144.73 Visa
2012-12-31 17:59 Gilbert Consumer Electronics 354.66 Discover
2012-12-31 17:59 Memphis Sporting Goods 124.79 Amex
2012-12-31 17:59 Chicago Men's Clothing 386.54 MasterCard
2012-12-31 17:59 Birmingham CDs 118.04 Cash
2012-12-31 17:59 Las Vegas Health and Beauty 420.46 Amex
2012-12-31 17:59 Wichita Toys 383.9 Cash
2012-12-31 17:59 Tucson Pet Supplies 268.39 MasterCard
2012-12-31 17:59 Glendale Women's Clothing 68.05 Amex
2012-12-31 17:59 Albuquerque Toys 345.7 MasterCard
2012-12-31 17:59 Rochester DVDs 399.57 Amex
2012-12-31 17:59 Greensboro Baby 277.27 Discover
2012-12-31 17:59 Arlington Women's Clothing 134.95 MasterCard
2012-12-31 17:59 Corpus Christi DVDs 441.61 Discover
[training@localhost udacity_training]$
```

Dans la Table 1 nous résumons les commandes les plus utilisées dans Hadoop HDFS. La commande Hadoop version donne Hadoop 2.0.0-cdh4.1.1, hadoop fs liste les commandes de manipulation du File System Shell. Une documentation est disponible ici, même si ce n'est pas l'exact version et qu'il existe des petites variantes :
http://archive.cloudera.com/cdh4/cdh/4/hadoop/hadoop-project-dist/hadoopcommon/CommandsManual.html#fs.

`hadoop fs -ls`	Afficher le contenu du répertoire racine
`hadoop fs -put file.txt`	Upload un fichier dans hadoop (à partir du répertoire courant linux)
`hadoop fs -get file.txt`	Download un fichier à partir de hadoop sur votre disque local
`hadoop fs -tail file.txt`	Lire les dernières lignes du fichier
`hadoop fs -cat file.txt`	Affiche tout le contenu du fichier
`hadoop fs -cat file.txt | less`	Lire le fichier page par page
`hadoop fs -mv file.txt newfile.txt`	Renommer le fichier
`hadoop fs -rm newfile.txt`	Supprimer le fichier
`hadoop fs -mkdir myinput`	Créer un répertoire
`hadoop fs -rm -f -r myinput`	Supprime un répertoire, et son contenu récursivement

TABLE 1 – Principales commandes de manipulation de fichiers HDFS