Big Data

- TP3 : Hadoop MAP/REDUCE -

Objectif :

L'objectif principal de ce TP est de vous familiariser avec l'utilisation de Hadoop en conjonction avec le langage de programmation Java pour la résolution de divers problème, tout en pratiquant l'exécution de jobs MapReduce en local et sur un cluster Hadoop.

Exercice 1 : Anagrammes

On dispose d'un fichier texte contenant une liste de mots courants. On souhaite déterminer quels mots sont des anagrammes.

On rappelle qu'un mot est une anagramme d'un autre si leurs lettres sont identiques (par exemple, « crane » et « ancre »).

Le but de cet exercice est d'écrire un programme MapReduce pour identifier et regrouper les anagrammes de cette liste. Vous pouvez tester ce programme avec l'exemple suivant:

Fichier en entrée

```
crane
imaginer
surface
metropole
migraine
structure
ancre
```

Résultat



```
crane ancre
imaginer migraine
```

Exercice 2 : Analyse des sentiments des clients sur Twitter

Une entreprise dispose d'un compte twitter pour son service après-vente, recevant plusieurs dizaines de milliers de tweets par jour. Elle cherche à déterminer le taux de satisfaction de ses clients à partir du compte twitter. Chaque heure, les *tweets* reçus sont exportés au sein d'un fichier texte.

Écrire un programme MapReduce qui permet de calculer le nombre de tweets selon les calsses suivantes : satisfait, insatisfait et incuoncluant.

Données d'entrée :

```
"@acme Votre service client est nul"
"@acme 30min d'attente... très insatisfait"
"Très satisfait par un produit super !! @acme"
"merci d'avoir RT @acme"
"@acme produit déjà cassé, super insatisfait !"
```

Résultat :

```
("insatisfait";2)
("satisfait";1)
("inconcluant";2)
```

Indication :

- On pourra définir des descripteurs de sentiments et les mots attachés, par exemple :
  - **Sentiment négatif :**"nul", "insatisfait", "bof", "incompétents", …
  - **Sentiment positif :** "satisfait", "super", "excellent", …
- Si deux sentiments contradictoires détectés : renvoyer inconcluant

Exercice 3 : Index web inversé

Soit un très grand ensemble de pages web. Pour chaque page p dans l'ensemble, on souhaite trouver l'ensemble des pages qui référencent p.

Exemple : Si dans les pages p1 et p2, il y a des liens vers la page q, alors nous avons :

Sources(q) : {p1, p2, ...}

Écrire un programme MapReduce permettant de générer un index web inversé en adoptant ka représentation simplifié suivante :

Fichier en entrée

```
P1:P2,P3
P2:P1,P4
P3:P1,P4
P4:P1,P2,P3
```



Résultat

```
P1: P2, P3, P4
P2:  P1,  P4
P3:  P1,  P4
P4: P2, P3
```